AI 售前方案

企业知识库 RAG POC

面向 AI 售前 / FDE 面试的方案说明

需求澄清 · 技术取舍 · 评测证据 · 交付边界

基于模拟企业资料的离线 POC

2026.10 | v0.1-enterprise-rag-poc



业务问题

企业知识分散，客服答复难以追溯

模拟客户场景

客服、实施与售前需要查询产品手册、版本差异、故障记录和部署要求。资料分散时，查找慢，答案也难说明依据。

产品咨询

版本、功能、限制

故障排查

现象、检查步骤、SLA

部署与权限

网络、模型、访问边界

本次 POC 验证

固定问题能否找到目标资料？
答案能否附引用？
证据不足时能否说明边界？

方案价值假设：让知识问答带来源，并在资料不足时进入人工确认。

收益需在客户问题集、现有流程和实际使用数据上验证。

需求澄清

先确认数据、权限与验收口径

资料

- 文档格式、数量与责任人
- 更新频率、版本与有效状态
- 敏感级别及允许的处理位置

使用与权限

- 用户角色、身份源与组织关系
- SSO、文档权限继承与审计
- 日均问题量、峰值并发与响应目标

验收与运营

- 客户问题集和可回答范围
- 引用、拒答、覆盖率的口径
- 人工审核、升级和运维责任

建议验收维度

检索命中与排序 / 答案覆盖与引用 / 拒答边界 / 延迟 / 权限测试

验收阈值由客户数据与风险等级共同确定。本次观察值不等于客户目标。

方案流程

答案链路在生成前后设置证据闸门

提问
API 校验

业务域过滤（domain=enterprise）

混合检索
向量 + BM25

合并排序
RRF / 可选重排

证据判断
不足则提示人工确认

生成回答
只基于证据

Claim 校验
引用与内容核对

Output Gate
放行或受控提示

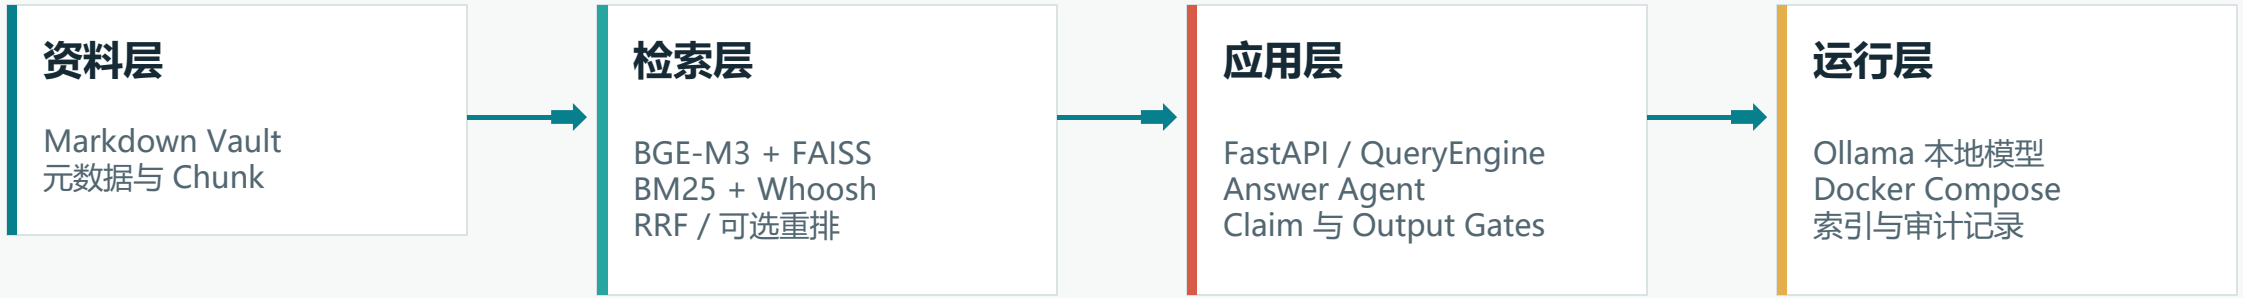
人工确认条件

证据不足 / 资料冲突 / 权限不明 / Claim 需要复核

判断：把拒答和人工复核作为方案能力的一部分，避免只展示“能回答”。

技术架构

混合检索连接模拟资料与受控生成



输入：16 篇模拟文档 / 45 个 chunk

输出：答案、Citation、置信度与边界提示

规模与部署判断

FAISS + Whoosh 适合本地 POC。生产规模、峰值 QPS、GPU、数据敏感性与运维要求明确后，再选择云上、混合或私有化组件。

DEMO 演示

固定问题覆盖产品、故障与部署主线

01	**产品咨询**	版本能力与产品限制	引用返回
02	**故障排查**	无法接收新工单	引用返回
03	**版本说明**	v1.1 与 v1.2 差异	引用返回
04	**私有化部署**	网络、模型与环境检查	引用返回
05	**边界问题**	无依据内容提示人工确认	边界表达

Docker 演示证据：5 / 5 场景通过；索引健康状态 ok；每个场景有 Citation。

安全边界要区分已实现与待交付

本地 POC 已验证

- API Token 鉴权与限流
- domain=enterprise 过滤
- Citation / Claim / Output Gate
- 索引健康检查与 Docker 演示

客户环境待验证

- 鉴权策略接入客户网关
- 业务域过滤映射客户资料
- Compose 与模型资源部署
- 客户网络、并发与响应表现

方案设计，尚未实现

- 真实 SSO、组织同步与 ACL
- 文档权限继承和越权审计
- 正式版本 / 生效状态过滤
- 增量索引、回滚、监控与告警

domain=enterprise 属于业务域过滤，不等于用户 ACL 隔离；当前未接真实 SSO 或企业 ACL。

POC 评测

检索命中较好，答案覆盖仍是主要短板

基于模拟企业资料的离线评测 | 评测日期：2026-10-08 | 代码基线：22dc574

指标	22 条完整问题集	5 条 core_demo 子集
Recall@5	**1.0000**	**1.0000**
MRR	**0.7935**	**0.8750**
Source coverage	**0.8519**	**0.8750**
Claim citation grounding	**0.8947**	**0.6667**
Claim semantic grounding	**0.7895**	**0.6667**
边界表达命中率（短语规则）	**4/4**	**1/1**
Answer point coverage	**0.4843**	**0.6458**
Claim review count	**8 条**	**4 条**

Docker 固定演示场景另计：5 / 5 场景通过，不与 core_demo 或 22 条全集混算。

注：边界表达命中率只按无依据 / 越权子集做短语规则匹配，不代表通用或生产拒答准确率。
Answer point coverage 为文本匹配诊断指标，不代表语义正确率。

部署与成本由数据、负载和运维责任决定

部署方式	适用条件	主要取舍
API	低敏感、低规模、快速验证	上线快，需评估外部数据处理要求
云上 / 混合	中等规模，需要数据隔离与弹性	平衡控制力和运维投入
私有化	高敏感或内网限制，负载较稳定	控制力高，需承担硬件和运维成本

API 月成本公式

问题量 × 平均输入 / 输出 Token × 工作日 × 供应商单价 + Embedding / 重排等调用

本材料只有假设参数与公式，不是报价。实际核算还要加入计算、存储、日志、GPU 和运维。

交付边界

POC 可复现，生产交付仍需客户数据验证

01	02	03	04
需求与数据	**质量优化**	**企业能力**	**客户验证**
确认权限、资料和验收集	优化答案覆盖；复核 8 条 Claim	补版本元数据、ACL、增量索引	压测、成本核算与试点验收

本次交付证据

可复现 Docker Demo ｜ 22 条离线评测 ｜ 架构与成本测算说明

限制：模拟资料，无真实客户收益数据；未接入真实 SSO / ACL；离线结果不构成生产准确率或 SLA。